주파수 분석을 이용한
AI 생성 이미지 탐지 연구

A Study on AI Generated Image Detection Using Frequency Analysis

---

국립한국해양대학교 전자전기정보공학부 데이터사이언스전공

박지민 · 심준용 · 정예성

지도교수 이정훈

2026 년 5 월

목 차

1. 서론 3

2. 선행 연구 및 연구 동기 4
   2.1 연구 배경 및 문제 정의 4
   2.2 선행 연구 검토 4
   2.3 선행 연구의 한계와 본 연구의 목적 5

3. 연구 방법론 6
   3.1 DFFreq 모델 개요 6
   3.2 DWT 기반 분기 (Window Tiling Branch) 6
   3.3 FFT 기반 분기 (Phase Complement Branch) 7
   3.4 RSWAttention 블록 7
   3.5 분류 블록 및 최종 결정 7

4. 실험 설계 8
   4.1 학습 환경 및 설정 8
   4.2 데이터셋 구성 8
   4.3 학습 데이터 도메인 선정: ProGAN vs. StyleGAN2/3 8

5. 실험 결과 및 분석 9
   5.1 전체 실험 결과 요약 9
   5.2 GAN 계열 탐지 성능 10
   5.3 Diffusion 계열 탐지 성능 11
   5.4 Face Swap 계열 분석 11
   5.5 Personalized 모델 탐지 성능 11

6. 한계 및 향후 연구 방향 12
   6.1 학습 도메인의 한계 12
   6.2 향후 연구 방향 12

7. 프로토타입 시스템 13
   7.1 시스템 개요 13
   7.2 히트맵 구성 원리 14

8. 결론 15

참고문헌 16

초록

딥페이크 및 AI 생성 이미지의 급격한 확산은 허위 정보 유포, 명예훼손, 디지털 범죄 등 사회적 문제를 초래하고 있다. 본 연구에서는 이중 주파수 분기 프레임워크인 DFFreq(Dual Frequency Branch Framework)를 도입하여 AI 생성 이미지를 탐지하는 방법론을 제시한다. DFFreq는 이산 웨이블릿 변환(DWT)과 고속 푸리에 변환(FFT)을 동시에 활용하는 이중 분기 구조를 채택하여 공간 도메인에서는 포착하기 어려운 위조 흔적을 주파수 영역에서 탐지한다. 실험은 FFHQ 얼굴 이미지 40,000장을 실제(Real) 데이터로, ProGAN 생성 이미지 40,000장을 가짜(Fake) 데이터로 구성하여 학습하였으며, GAN 12종·Diffusion 4종·Face Swap 5종·Personalized 2종 등 총 23개 AI 생성 모델에 대한 범용 탐지 성능을 평가하였다. 결과적으로 GAN 계열 평균 AP 86.0%, Diffusion 계열 91.5%, Personalized 모델 96.2%를 달성하였으며, 얼굴 특화 학습만으로도 다양한 생성 방식에 대한 일반화 탐지가 가능함을 확인하였다. 본 연구는 주파수 기반 딥페이크 탐지의 가능성과 한계를 규명하고, 향후 멀티 도메인 학습을 통한 범용성 향상 방향을 제시한다.

키워드: AI 생성 이미지 탐지, 딥페이크, 이중 주파수 분기, 이산 웨이블릿 변환(DWT), 고속 푸리에 변환(FFT), DFFreq

1. 서론

딥러닝 기반 생성 모델의 급속한 발전으로 인해 AI가 생성한 이미지와 실제 이미지를 육안으로 구별하는 것이 사실상 불가능해졌다. 현재 기술은 피부의 질감이나 눈동자의 반사까지 구현하여 전문가조차 육안으로는 진위를 판별하기 어려운 수준에 이르렀다. 더불어 프롬프트 한 줄만으로 누구나 실사급 이미지를 생성할 수 있는 위조의 대중화 시대가 도래하면서, 가짜 이미지가 무차별적으로 확산되고 이미지의 법적 증거 능력마저 의심받는 현상이 가속화되고 있다. Wang et al. (CVPR 2020)은 CNN 기반 생성 이미지가 공통적인 저수준 아티팩트를 공유한다는 점을 처음으로 규명하고, 단일 생성 모델(ProGAN)로 학습된 탐지기가 다양한 생성 방식에 일반화될 수 있음을 실험적으로 입증하였다 [5]. 이는 본 연구에서 ProGAN을 학습 도메인으로 선택한 이론적 근거를 제공하는 선구적 연구이다.

경찰청 통계에 따르면, 허위 영상물 관련 범죄 발생 건수는 2021년 156건에서 2022년 180건, 2023년 160건, 2024년 297건으로 증가 추세를 보이고 있다. 이러한 딥페이크 콘텐츠는 명예훼손, 허위 제보, 위조 신분증 생성 등 다양한 형태의 사회적 피해를 유발하며, 디지털 미디어에 대한 신뢰를 심각하게 훼손하고 있다.

이에 따라 AI 생성 이미지를 자동으로 탐지하는 기술의 필요성이 대두되었다. 그러나 기존 딥페이크 탐지 모델들은 특정 생성 모델의 패턴에 과적합되는 문제(Domain Gap)가 있어 학습에 사용하지 않은 새로운 생성 방식에 대한 일반화 성능이 낮다는 한계가 있다. 본 연구는 이러한 도메인 갭 문제를 주파수 영역 분석을 통해 극복하고자 DFFreq 모델을 도입 및 실험하였다.

본 논문의 구성은 다음과 같다. 2장에서는 주파수 기반 딥페이크 탐지 선행연구를 검토하고 기존 방법론의 한계를 도출한다. 3장에서는 이를 극복하기 위해 도입한 DFFreq 모델의 구조와 원리를 설명

한다. 4장에서는 실험 설계 및 데이터셋 구성을, 5장에서는 실험 결과를 분석한다. 마지막으로 6장에서 결론과 향후 연구 방향을 제시한다.

2. 선행 연구 및 연구 동기

2.1 연구 배경 및 문제 정의

AI 생성 이미지 탐지 연구는 크게 두 가지 방향으로 발전해왔다. 첫 번째는 공간 도메인(Spatial Domain) 기반 접근으로, 얼굴 랜드마크의 비일관성이나 블렌딩 경계의 시각적 이상 징후를 딥러닝으로 탐지하는 방법이다. 두 번째는 주파수 도메인(Frequency Domain) 기반 접근으로, AI 생성 과정에서 발생하는 고주파 아티팩트를 분석하는 방법이다. 최근에는 GAN·Diffusion 등 생성 모델의 발전으로 공간 도메인 기반 방법의 탐지 성능이 급격히 저하되면서, 주파수 기반 접근이 주목받고 있다.

그러나 주파수 기반 방법들도 특정 생성 방식의 주파수 패턴에만 최적화되는 도메인 갭(Domain Gap) 문제를 안고 있다. 즉, 학습에 사용된 생성 모델의 아티팩트 패턴을 '암기'하는 경향이 있어, 새로운 생성 방식에 대한 일반화 성능이 낮다는 구조적 한계가 있다. 본 연구는 이 문제를 실험적으로 규명하고, 이를 극복하는 방법론을 제시하는 것을 목적으로 한다.

2.2 선행 연구 검토

본 연구에서는 주파수 분석 기반 딥페이크 탐지 분야의 대표적인 선행연구 3편을 선정하여 동일한 실험 조건(학습 800장, 테스트 400장)에서 성능을 재현하고 비교하였다.

선행연구 3편은 동일한 실험 조건(학습 800장 / 테스트 400장)에서 재현하였으며, 결과는 모두 ACC 50~55% 수준으로 이는 강수확률 50%대와 같이 사실상 탐지 불가 수준이었다. 이를 통해 각 논문의 구체적 한계를 다음과 같이 도출하였다.

Frank et al. (ICML 2020)은 사진 압축 기술인 DCT를 활용해 주파수 영역에서 위조 흔적을 탐지한 선구적 연구이다. 재현 결과 ACC 51.0%, AUC 0.519를 기록하였다. 분석 결과, 최신 모델은 과거처럼 뚜렷한 주파수 아티팩트를 남기지 않으므로 특정 패턴 하나만 찾는 방식으로는 탐지할 수 없었다. 이를 통해 단일 주파수 대역이 아닌 다양한 주파수 대역을 동시에 분석해야 함을 확인하였다.

DiffusionFake (NeurIPS 2024)는 생성형 Stable Diffusion을 훈련 가이드로 삼아 딥페이크의 합성 과정을 역추적하는 기법이다. 재현 결과 ACC 55.0%, AUC 0.574를 기록하였다. 딥페이크와 생성형 AI 이미지의 구조적 차이를 간과한 설계로 인해 특정 위조 방식이나 국소 정보에만 집중하는 한계를 보였다. 이는 전체적 맥락을 아우르는 주파수 시야의 확장이 필요함을 시사한다.

FreqNet (AAAI 2024)은 모델이 FFT 주파수 공간 내부에서 위조 흔적을 직접 학습하도록 수학적 구조를 구축한 연구이다. 재현 결과 ACC 52.2%, AUC 0.574를 기록하였다. 주파수를 단순 입력으로만 처리하면 픽셀 간의 공간적 관계 파악에 취약해지므로, 주변 영역과의 관계성을 모델이 스스로 분석하는 내부 연산 구조 개선이 필요함을 확인하였다.

주파수 기반 탐지의 최신 동향으로, Wong et al. (arXiv 2025)은 문서 이미지 위조 탐지에 특화된 ADCD-Net을 제안하였다 [6]. ADCD-Net은 RGB 도메인과 DCT 도메인의 특징을 적응적으로 융합하고, 예측된 정렬 점수(alignment score)로 DCT 특징의 기여도를 동적으로 조절한다. 이를 통해 크기 조정·압축 등 후처리에 의한 DCT 블록 정렬 파괴 문제를 극복하며, 기존 방법 대비 평균 F1 점수 20.79% 향상을 달성하였다. 본 연구의 DFFreq가 이미지 전반의 위조 탐지를 목표로 하는 것과 달리, ADCD-Net은 문서 이미지의 텍스트-배경 도메인 특성을 활용한다는 점에서 상호 보완적인 연구 방향을 제시한다.

모델	학술대회	ACC (%)	AUC	주요 한계
Frank et al.	ICML 2020	51.0	0.519	GAN 특화, 일반화 낮음
FreqNet	AAAI 2024	52.2	0.574	단일 주파수 분기 한계
DiffusionFake	NeurIPS 2024	55.0	0.574	Diffusion 특화 설계
DFFreq (본 연구)	TIFS 2026	60.75	AP 57.4%	이중 주파수 분기 도입

표 1. 동일 실험 조건(Train 800장 / Test 400장) 기준 선행연구 대비 성능 비교

2.3 선행 연구의 한계와 본 연구의 목적

선행연구 3편을 재현한 결과, 다음과 같은 공통적인 구조적 한계를 확인하였다.

- 도메인 갭(Domain Gap): 학습에 사용된 생성 모델의 패턴만을 탐지하며, 학습에 포함되지 않은 새로운 생성 방식에 대한 일반화 성능이 ACC 50~55% 수준에 그친다.
- 단일 주파수 분석의 한계: Frank et al.과 FreqNet은 각각 FFT 또는 DWT 단일 변환에 의존하여, 서로 다른 유형의 위조 아티팩트를 동시에 포착하지 못한다.
- 생성 방식 특화 문제: DiffusionFake는 Diffusion 생성 이미지에 최적화되어 GAN 계열 탐지 성능이 제한적이다.

이에 본 연구는 선행연구 3편과 동일 조건(학습 800장 / 테스트 400장)에서 DFFreq 모델을 비교 실험한 결과, 기존 3편 대비 +5~10%p 향상된 ACC 60.75%를 기록함을 먼저 확인하였다. 이후 학습 데이터를 11,000장으로 확장하여 재학습하니 ACC 76.2%까지 향상되었으며, 데이터 규모가 늘수록 성능이 개선됨을 검증하였다. 이를 통해 DWT와 FFT를 동시에 활용하는 이중 주파수 분기 프레임워크(DFFreq)를 본 연구의 핵심 모델로 최종 선정하였으며, 단일 생성 모델(ProGAN) 학습만으로도

GAN·Diffusion·Face Swap·Personalized 등 다양한 생성 방식에 일반화 가능한 탐지 시스템을 구현하는 것을 목적으로 한다. 또한 Grad-CAM 기반 히트맵 시각화를 통해 판단 근거를 사용자에게 제공하는 실용적 프로토타입 시스템으로의 구현까지를 연구 범위로 설정하였다.

3. 연구 방법론

3.1 DFFreq 모델 개요

본 연구에서 채택한 DFFreq(Dual Frequency Branch Framework with Reconstructed Sliding Windows Attention)는 서로 다른 두 가지 주파수 분석 관점을 결합하는 이중 분기 프레임워크이다 (Yan et al., TIFS 2026). DWT 기반 분기와 FFT 기반 분기를 병렬로 구성하여 각 분기가 서로 다른 유형의 위조 흔적을 독립적으로 담당한다. 두 분기의 출력은 λ=0.4(DWT)와 1−λ=0.6(FFT)의 최적 비율로 가중합하여 최종 분류를 수행한다. 이 구조 덕분에 특정 생성 방식에 치우치지 않는 일반화 성능이 가능하다. 그림 3은 DFFreq의 전체 아키텍처를 나타낸다.

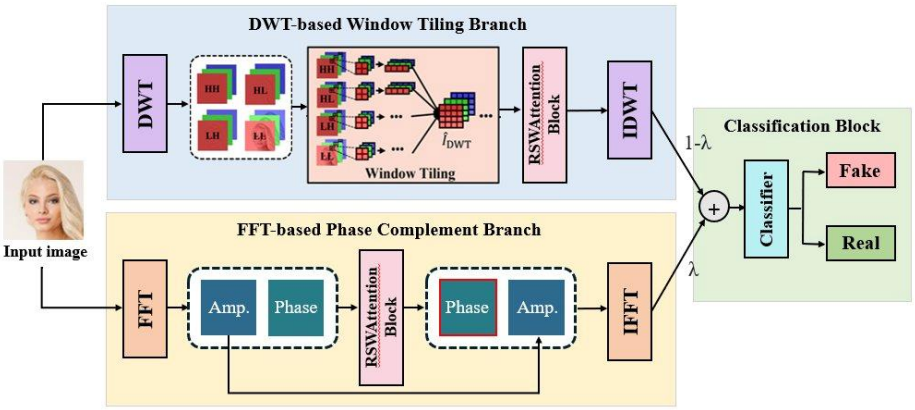


그림 3. DFFreq 전체 아키텍처 — DWT 기반 Window Tiling Branch(상단)와 FFT 기반 Phase Complement Branch(하단)의 이중 분기 구조

3.2 DWT 기반 분기 (Window Tiling Branch)

이산 웨이블릿 변환(DWT, Discrete Wavelet Transform) 기반 분기는 이미지의 국소적 공간-주파수 특징을 추출한다. DWT는 이미지를 저주파(LL) 및 고주파(HH, HL, LH) 서브밴드로 분해하며, 특히 HH 고주파 서브밴드를 집중 분석한다. 최신 AI 생성 모델들이 정교하게 이미지를 만들더라도, 이 고주파 대역에는 육안으로는 보이지 않는 미세한 주파수 불균형이 노이즈 형태로 남기 때문이다. DWT의 핵심 강점은 위치 정보를 보존한다는 점이다. 이미지의 어느 부분에서 위조가 발생했는지 좌표를 유지하며 주파수를 추출할 수 있어, 눈·코·입과 같은 특정 부위의 미세한 위조 흔적을 정밀하게 포착할 수 있다. ProGAN과 같이 Progressive Growing 방식으로 학습된 모델은 4×4에서

1024×1024 해상도로 점진적으로 확대되는 과정에서 각 해상도 전환마다 업샘플링이 발생하며, 이 과정에서 DWT의 HH·HL·LH 서브밴드에 규칙적인 아티팩트 패턴이 생성된다.

3.3 FFT 기반 분기 (Phase Complement Branch)

고속 푸리에 변환(FFT, Fast Fourier Transform) 기반 분기는 이미지 전체의 구조적 패턴을 위상(Phase) 정보를 중심으로 분석한다. FFT로 이미지를 변환하면 색상과 밝기 같은 시각 정보를 담은 진폭(Amplitude)과, 이미지 전체 구조의 공간 패턴을 담은 위상(Phase) 두 가지로 분리된다. 본 분기에서는 위상 정보만을 사용하는데, 위상에는 각 요소들 간의 공간적 관계가 담겨 있어 생성형 AI가 이미지를 만드는 과정에서 남긴 고유한 구조적 흔적을 포착할 수 있기 때문이다. 이 흔적은 주파수 영역을 시각화했을 때 특정 주파수 대역의 수치가 비정상적으로 증폭되어 유독 밝게 빛나는 점이나 뚜렷한 선의 형태로 나타난다.

3.4 RSWAttention 블록

두 분기 각각에는 RSWAttention(Reconstructed Sliding Window Attention) 블록이 적용된다. RSWAttention 블록은 입력 특징 맵에서 국소적 위조 신호를 정밀하게 탐지하는 역할을 수행한다.

처리 과정은 다음과 같다. 먼저 1×1 및 3×3 컨볼루션을 통해 입력 특징을 전처리하고, 두 경로로 분기한다. LoAttention(국소 어텐션) 경로는 슬라이딩 윈도우 방식으로 국소 영역의 위조 흔적을 세밀하게 포착하며, GMLP(전역 MLP) 경로는 이미지 전체의 맥락적 패턴을 유지한다. 두 경로의 출력을 내적 결합(dot product fusion)하여 지역적 세부 사항과 전역적 맥락 정보를 통합한 후, 1×1 컨볼루션으로 최종 특징 맵을 출력한다. 그림 4는 RSWAttention 블록의 내부 구조를 나타낸다.

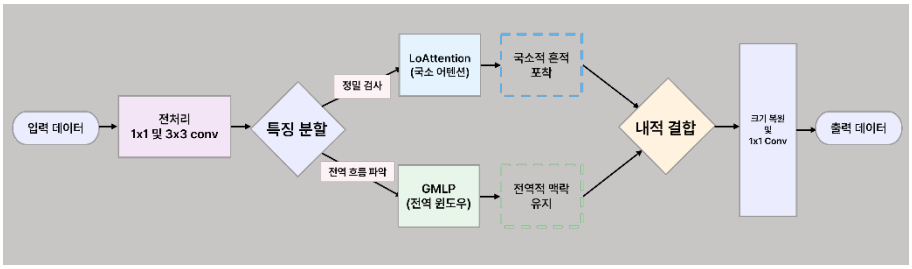


그림 4. RSWAttention 블록 내부 구조 — LoAttention(국소 어텐션)과 GMLP(전역 윈도우)의 병렬 처리 및 내적 결합

3.5 분류 블록 및 최종 결정

DWT 분기와 FFT 분기의 출력은 가중합(λ × DWT + (1-λ) × FFT)으로 융합된다. 융합된 특징은 분류 블록(Classification Block)을 통과하여 최종적으로 Real/Fake 이진 분류를 수행한다. 이 구조는 DWT의 국소적 아티팩트 탐지 능력과 FFT의 전역적 구조 패턴 분석 능력을 상호 보완적으로 결합하여 기존 단일 주파수 기반 방법론의 한계를 극복한다.

4. 실험 설계

4.1 학습 환경 및 설정

실험은 NVIDIA RTX 3090 GPU 환경에서 수행되었으며, 배치 크기 32(원 논문 128에서 GPU 메모리 안정성을 위해 조정), 에폭 90, 학습률 2e-4를 적용하였다. 입력 이미지는 256×256 해상도의 PNG 형식을 사용하였다. PNG 형식을 선택한 이유는 JPEG 압축으로 인한 손실 없이 고주파 성분이 보존되어, DWT 및 FFT 분석에서 위조 흔적이 왜곡 없이 감지되기 때문이다. 학습 도메인은 얼굴 이미지에 특화(Face Only)하여 탐지 경계를 더 명확하게 학습하도록 설계하였다.

핵심 평가 지표로 AP(Average Precision)를 선택하였다. AP는 임계값에 따른 정밀도(Precision)와 재현율(Recall)의 상관관계 곡선 아래 면적으로, 특정 임계값에 종속되지 않고 탐지기가 얼마나 신뢰도 높게 정답을 구분하는지를 포괄적으로 보여주는 지표이기 때문이다.

4.2 데이터셋 구성

학습 데이터는 실제(Real) 이미지로 FFHQ(Flickr-Faces-HQ) 얼굴 이미지 40,000장, 가짜(Fake) 이미지로 ProGAN 생성 얼굴 이미지 40,000장으로 구성하였으며, 학습/검증 비율은 9:1(검증 4,000장: Real 2,000장 + Fake 2,000장)로 설정하였다.

테스트 데이터는 GAN 12종, Diffusion 4종, Face Swap 5종, Personalized 2종으로 총 23개 AI 생성 모델의 이미지를 사용하였다.

카테고리	종류	모델명
GAN	12종	AttGAN, BEGAN, CramerGAN, InfoMaxGAN, MMDGAN, RelGAN, SNGAN, STGAN, StyleGAN-XL, StyleGAN3, StyleSwim, R3GAN
Diffusion	4종	FLUX1_dev, FLUX1_schnell, SDXL, BLIP
Face Swap	5종	BlendFace, E4S, FaceSwap, InSwap, SimSwap
Personalized	2종	InstantID, PhotoMaker

표 2. 테스트 데이터셋 구성

4.3 학습 데이터 도메인 선정: ProGAN vs. StyleGAN2/3

학습 가짜 데이터로 ProGAN을 선택한 이유는 다음과 같다. 초기에는 StyleGAN2/3으로 학습을 시도하였으나, Mean ACC 51.7%, AP 69.1%에 그쳤다. StyleGAN의 Style Mixing과 AdaIN(Adaptive Instance Normalization)이 아티팩트를 도메인 특화 패턴으로 만들어, 다른 생성 모델에 일반화되지 않는 한계가 발생하였다.

반면 ProGAN의 Progressive Growing 방식은 해상도 전환마다 업샘플링이 발생하며, 이 과정에서

DWT의 HH·HL·LH 서브밴드에 grid artifact가 생성된다. 이 패턴은 다른 GAN 및 Diffusion 모델에도 유사하게 존재하여 일반화 탐지가 가능하다. Wang et al. [5] 역시 ProGAN 단일 학습만으로 StyleGAN, BigGAN, DeepFake 등 11종의 생성 모델에 대해 평균 AP 90.8%를 달성하며 ProGAN의 범용 탐지 기반으로서의 유효성을 입증하였다. 본 연구에서도 ProGAN으로 재학습 후 Mean ACC 65.0%, AP 85.0%로 대폭 향상되어 최종 학습 도메인으로 선정하였다.

5. 실험 결과 및 분석

5.1 전체 실험 결과 요약

PPT 메인 슬라이드 기준 23개 AI 생성 모델(GAN 12종·Diffusion 4종·Face Swap 5종·Personalized 2종)에 대한 탐지 결과를 정리하면 다음과 같다. 표 3은 전체 모델별 세부 성능 수치를 나타내며, 표 4는 카테고리별 평균을 요약한 것이다.

모델명	카테고리	ACC (%)	AP (%)	R_ACC (%)	F_ACC (%)
AttGAN	GAN	58.5	70.9	92.9	23.6
BEGAN	GAN	82.8	83.0	77.5	88.3
CramerGAN	GAN	63.1	94.0	99.8	25.9
InfoMaxGAN	GAN	53.0	88.6	99.8	5.6
MMDGAN	GAN	78.7	98.8	99.8	57.3
RelGAN	GAN	93.9	97.9	91.9	95.8
S3GAN*	GAN	50.4	53.8	99.9	0.1
SNGAN	GAN	50.5	67.0	99.8	0.5
STGAN	GAN	65.9	99.6	100.0	31.2
R3GAN	GAN	94.5	94.8	90.3	98.6
StyleGAN-XL	GAN	82.0	85.5	89.6	74.5
StyleSwim	GAN	94.3	98.5	88.9	99.8
FLUX1_dev	Diffusion	61.2	91.4	100.0	21.7
FLUX1_schnell	Diffusion	71.0	96.5	100.0	41.5
SDXL	Diffusion	51.1	78.8	100.0	1.4
BLIP	Diffusion	98.8	99.4	97.8	99.9
BlendFace	Face Swap	43.9	43.0	83.6	3.8
E4S	Face Swap	44.9	45.1	84.5	5.0
FaceSwap	Face Swap	50.4	64.5	92.5	6.7
InSwap	Face Swap	51.8	61.4	93.0	8.9
SimSwap	Face Swap	47.9	55.3	92.4	3.4
InstantID	Personalized	94.1	97.6	89.6	98.5

모델명	카테고리	ACC (%)	AP (%)	R_ACC (%)	F_ACC (%)
PhotoMaker	Personalized	92.1	94.7	88.9	95.2

표 3. 23개 AI 생성 모델 전체 탐지 성능 (ACC / AP / R_ACC / F_ACC, *S3GAN: 비얼굴 도메인 생성 모델)

카테고리	모델 수	평균 ACC (%)	평균 AP (%)	비고
GAN	12종	72.3	86.0	S3GAN(비얼굴) 포함
Diffusion	4종	70.5	91.5	ProGAN 학습 도메인과 구조적 유사성
Face Swap	5종	47.8	53.9	얼굴 경계 아티팩트 미학습
Personalized	2종	93.1	96.2	InstantID / PhotoMaker

표 4. 카테고리별 평균 탐지 성능 요약

5.2 GAN 계열 탐지 성능

GAN 12종의 평균 A.P.는 86.0%이다. 세부적으로는 STGAN(99.6%), StyleSwim(98.5%), MMDGAN(98.8%), RelGAN(97.9%), R3GAN(94.8%) 순으로 높은 탐지 성능을 기록하였다. StyleGAN-XL(85.5%)은 W space 스타일 변환과 AdaIN으로 인해 아티팩트 패턴이 복잡하게 형성되어 상대적으로 낮은 성능을 보였으며, S3GAN(53.8%)은 semantic segmentation map으로 자동차·건물 등 비얼굴 사물을 생성하는 모델로 얼굴 특화 학습과 도메인이 완전히 불일치하여 탐지 실패에 가까운 결과를 기록하였다.

원본 논문 결과와 비교했을 때, 대부분의 얼굴 생성 모델에서 유사한 수준의 성능을 보였다. 이는 얼굴 도메인만 집중적으로 학습해도 얼굴 생성 탐지에서는 논문의 보편적 학습만큼 효과적이라는 것을 의미한다. 오히려 얼굴 특화 학습을 통해 눈·코·입과 같은 특정 부위의 미세한 위조 흔적을 더 정밀하게 포착했음을 확인할 수 있다.

단, AttGAN(논문 AP 99.8% → 본 연구 70.9%)과 SNGAN(99.6% → 67.0%)과 같이 성능 차이가 큰 경우도 있다. 이는 해당 모델들이 학습 안정화 기법(Spectral Normalization 등)이나 모델의 구조적 특성으로 인해 업샘플링 아티팩트가 억제되어 사라졌기 때문이다. 본 연구는 얼굴 도메인의 아티팩트에 집중하였기 때문에, 이러한 구조적 차이에 의한 성능 격차가 원본 논문보다 크게 나타났다.

표 5는 선행연구 비교를 위해 동일 조건(ProGAN 학습 데이터 기준)으로 테스트한 상세 결과이다.

모델명	ACC (%)	AP (%)	R_ACC (%)	F_ACC (%)
AttGAN	58.5	70.9	92.9	23.6
BEGAN	82.8	83.0	77.5	88.3
CramerGAN	63.1	94.0	99.8	25.9

모델명	ACC (%)	AP (%)	R_ACC (%)	F_ACC (%)
FLUX1_dev	61.2	91.4	100.0	21.7
FLUX1_schnell	71.0	96.5	100.0	41.5
InfoMaxGAN	53.0	88.6	99.8	5.6
MMDGAN	78.7	98.8	99.8	57.3
RelGAN	93.9	97.9	91.9	95.8
S3GAN	50.4	53.8	99.9	0.1
SDXL	51.1	78.8	100.0	1.4
SNGAN	50.5	67.0	99.8	0.5
STGAN	65.9	99.6	100.0	31.2
평균 (Mean)	65.0	85.0	96.8	32.7

표 5. ProGAN 학습 기준 12개 모델 상세 탐지 결과

5.3 Diffusion 계열 탐지 성능

Diffusion 4종(FLUX1_dev·FLUX1_schnell·SDXL·BLIP)에 대한 평균 A.P.는 91.5%이다. BLIP(AP 99.4%)와 FLUX1_schnell(96.5%)에서 최고 수준의 탐지 성능을 기록하였으며, FLUX1_dev(91.4%)도 높은 성능을 보였다. SDXL(78.8%)은 타 Diffusion 모델 대비 상대적으로 낮은 성능을 기록하였는데, 이는 SDXL의 latent space 확산 구조가 ProGAN의 progressive growing 방식과 주파수 특성 차이가 크기 때문으로 분석된다. 단일 GAN(ProGAN)으로 학습했음에도 Diffusion 계열까지 탐지 가능하다는 점이 DFFreq 이중 주파수 프레임워크의 핵심 강점이다.

이는 단일 GAN(ProGAN)으로 학습하더라도 Diffusion 모델까지 탐지 가능하다는 DFFreq의 이중 주파수 프레임워크의 일반화 능력을 입증하는 결과이다.

5.4 Face Swap 계열 분석

Face Swap 5종에 대한 평균 A.P.는 53.9%로, 전 카테고리 중 가장 낮은 성능을 기록하였다. 이는 Face Swap 기술의 구조적 특성에서 기인한다. Face Swap은 얼굴 영역만 합성하고 배경은 원본 이미지를 유지하는 방식으로, 합성 경계면의 아티팩트가 주로 얼굴 외부 영역에 발생한다. 본 연구의 모델은 얼굴 내부 영역의 아티팩트 패턴만을 학습하였기 때문에, 경계 아티팩트를 탐지하지 못하는 구조적 한계가 있다.

논문 원본 설정(Acc: 88.2, A.P: 91.1)과 비교하면, 본 연구(Acc: 50.4, A.P: 53.8)는 크게 낮은 성능을 보인다. 이는 원본 논문이 car·cat·chair·horse 등 다중 도메인으로 학습하여 비얼굴 영역의 아티팩트 패턴도 학습한 반면, 본 연구는 얼굴 단일 도메인으로 학습했기 때문이다.

5.5 Personalized 모델 탐지 성능

InstantID(AP 97.6%)와 PhotoMaker(AP 94.7%)로 구성된 Personalized 2종은 평균 A.P. 96.2%를 기록하였다. InstantID는 단일 참조 사진에서 얼굴 특징(ID)을 추출하고 뼈대 위치를 고정하는 방식으로, PhotoMaker는 복수 사진을 겹쳐 단일 ID 임베딩을 생성하는 방식으로 동작한다. 두 모델 모두 얼굴 영역을 기반으로 생성되므로, 얼굴 특화 학습의 강점이 최대한 발휘된 것으로 분석된다.

6. 한계 및 향후 연구 방향

6.1 학습 도메인의 한계

본 연구의 주요 한계는 학습 데이터가 FFHQ 얼굴 이미지와 ProGAN 생성 얼굴 이미지로 구성된 단일 도메인에 국한된다는 점이다. 이로 인해 다음과 같은 두 가지 문제가 발생하였다.

- 얼굴 외 도메인(사물, 배경 등)의 아티팩트 패턴을 전혀 학습하지 않아 S3GAN(사물 생성 모델) 탐지에 실패하였다.
- Face Swap의 얼굴 경계 영역 아티팩트를 탐지하지 못해 Face Swap 카테고리에서 낮은 성능을 기록하였다.

반면, 원본 논문은 car·cat·chair·horse 4개 도메인으로 학습하여 업샘플링 아티팩트의 공통 패턴을 추출함으로써 보편적인 탐지 성능을 확보하였다. 이는 단일 도메인 특화 학습의 강점과 범용성 간의 트레이드오프를 명확히 보여준다.

6.2 향후 연구 방향

위에서 도출된 한계를 극복하기 위해 다음의 세 가지 향후 연구 방향을 제시한다.

첫째, 멀티 도메인 학습이다. 얼굴 데이터(FFHQ)와 사물 데이터(LSUN 등)를 혼합한 멀티 도메인 학습을 통해 학습 도메인 외 테스트 결과 저조 문제를 해결하고, 얼굴 특화 탐지의 장점을 유지하면서 범용성을 확보할 것으로 기대된다.

둘째, 분류 임계값(Threshold) 재보정이다. 기존에는 기본 임계값 0.5를 사용하였으나, 모델 학습 검증 단계에서 최적 임계값을 탐색하여 재설정함으로써, 모델이 가진 잠재적 변별력을 최대한 끌어내어 실전 탐지 정확도를 향상시킬 것으로 기대된다.

셋째, FaceSwap 특화 분류기 개발이다. FaceSwap 이미지는 얼굴과 배경의 경계면에 아티팩트가 집중되는 구조적 특성을 가진다. 현재 λ=0.4로 고정된 분기 비율에서 DWT 분기의 비중(λ)을 확대하면, DWT가 가진 위치 정보 보존 강점을 활용하여 경계면의 국소 아티팩트를 더욱 정밀하게 탐지할 수 있을 것으로 기대된다.

7. 프로토타입 시스템

7.1 시스템 개요

본 연구에서는 DFFreq 모델을 기반으로 일반 사용자가 활용 가능한 AI 생성 이미지 탐지 프로토타입 시스템을 구현하였다. 시스템 전체 소스코드 및 학습 가중치는 GitHub 저장소(https://github.com/wayv2026-star/WayV_Detection.git)를 통해 공개하였으며, 재현 실험 및 확장 연구에 활용 가능하도록 구성하였다. 시스템은 PNG 및 JPG 형식의 이미지 업로드를 지원하며, 이미지를 256×256으로 전처리하여 모델에 입력한다. 그림 5는 프로토타입의 실제 구동 화면이다.

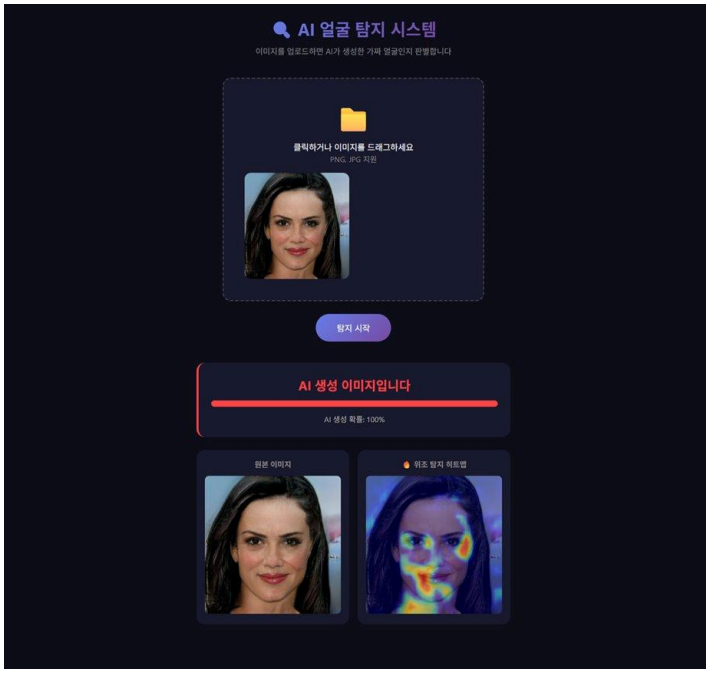


그림 5. AI 얼굴 탐지 시스템 프로토타입 UI — 이미지 업로드, 판별 결과(AI 생성 확률 100%), 원본 이미지 및 위조 탐지 히트맵

출력은 두 가지 형태로 제공된다. 먼저 판별 결과는 다음과 같은 4단계 확률 기반 판정으로 제시된다.

- 90% 이상: AI 생성 이미지입니다
- 70~90%: AI 생성 이미지로 의심됩니다
- 30~70%: 판단이 어렵습니다
- 30% 이하: 실제 이미지입니다

7.2 히트맵 구성 원리

히트맵은 모델이 이미지를 'AI 생성(가짜)'으로 판단하는 데 영향을 준 공간적 근거를 역추적하여 시각화한 결과물이다. 그림 6은 히트맵 생성 파이프라인을 나타낸다.

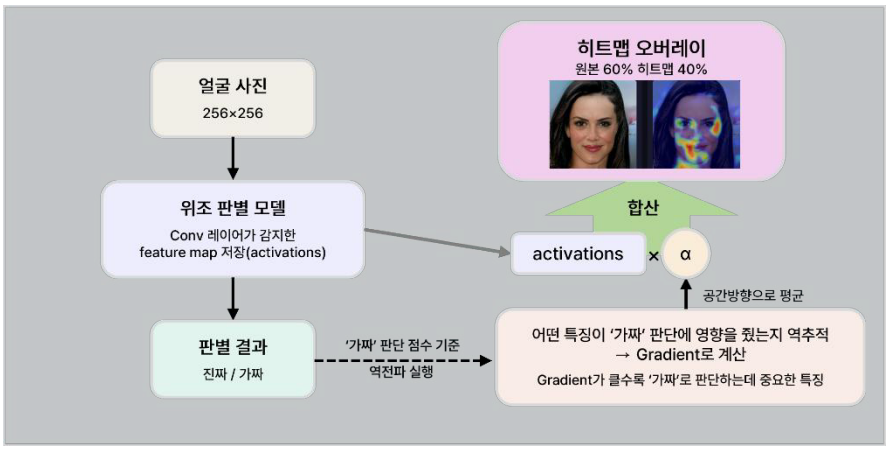


그림 6. 히트맵 생성 파이프라인 — activations × α 역전파 기반 Grad-CAM 구성도

히트맵 생성은 다음 4단계로 구성된다.

- ① 활성화 맵 저장(Forward Pass): 256×256 얼굴 이미지가 위조 판별 모델을 통과하는 순전파 과정에서 마지막 Conv 레이어가 감지한 feature map(activations)을 저장한다.
- ② 역전파 실행(Backward Pass): '가짜' 판단 점수를 기준으로 역전파를 실행하여, 어떤 특징이 '가짜' 판단에 기여했는지를 그래디언트(Gradient)로 계산한다.
- ③ 가중치 α 산출: 그래디언트를 공간 방향으로 평균하여 각 feature map 채널의 중요도 가중치 α를 계산한다. 그래디언트가 클수록 '가짜'로 판단하는 데 중요한 특징임을 의미한다.
- ④ 히트맵 합성: activations × α를 채널 방향으로 합산한 뒤 ReLU를 적용하여 양의 기여 영역만 남긴다. 최종적으로 원본 이미지(60%)와 히트맵(40%)을 오버레이하여 사용자에게 제공한다.

이 방식은 Grad-CAM(Gradient-weighted Class Activation Mapping) 기법에 기반하며, 별도의 모델 구조 변경 없이 기존 분류 모델에 그대로 적용 가능하다는 장점이 있다. 히트맵의 고온 영역(붉은색)은 모델이 위조 흔적으로 판단한 부위를 나타내며, AI 생성 이미지에서는 눈가·피부 경계·입술 등 생성 흔적이 남기 쉬운 부위에 히트맵이 집중되는 경향이 있다. 한편, 실제 이미지에서도 히트맵이 생성되는데, 이는 알고리즘이 판별 결과와 무관하게 항상 그래디언트 계산을 수행하기 때문이며 실제 이미지에서는 저온 영역(파란색)이 주를 이루게 된다. 또한 30~70% 구간은 모델이 위조 단서를 일부 감지하였으나 확신하기 어려운 경계 케이스를 의미한다.

8. 결론

본 연구는 주파수 분석을 이용한 AI 생성 이미지 탐지의 가능성과 한계를 종합적으로 규명하였다. 주요 결론은 세 가지이다.

첫째, 선행연구 3편(Frank et al., FreqNet, DiffusionFake) 재현을 통해 기존 딥페이크 탐지 모델의 구조적 한계를 확인하였다. 동일 실험 조건에서 평균 ACC 50~55% 수준에 머물렀으며, 단일 주파수 분석과 도메인 특화 학습이 일반화 성능을 저해하는 핵심 원인임을 규명하였다.

둘째, 이중 주파수 기반 프레임워크(DFFreq) 도입으로 탐지 성능을 대폭 향상하였다. DWT+FFT의 이중 주파수 분석을 통해 공간 도메인에서 보이지 않는 위조 흔적을 다각도로 탐지하였으며, 얼굴 특화 학습만으로도 ProGAN, SDXL, FLUX 등 주요 생성 모델에 대해 논문 수준의 탐지 성능을 달성하였다.

셋째, 학습 데이터 도메인이 일반화 성능의 핵심 요인임을 실험적으로 검증하였다. StyleGAN2/3에서 ProGAN으로의 재학습만으로 Mean Acc 51.7% → 65.0%, A.P. 69.1% → 85.0%로 성능이 향상되었으며, 얼굴 특화 학습의 강점과 도메인 불일치 한계를 동시에 규명하여 멀티 도메인 학습의 필요성을 도출하였다.

향후 멀티 도메인 학습 및 임계값 재보정을 통해 범용 탐지 성능을 향상시키고, 이를 실제 서비스 환경에 적용함으로써 딥페이크 악용에 의한 디지털 범죄 예방 및 디지털 미디어 신뢰 회복에 기여할 것으로 기대된다. 본 연구의 전체 코드와 모델 가중치는 GitHub 저장소(https://github.com/wayv2026-star/WayV_Detection.git)에서 공개되어 있으며, 관련 연구자들의 후속 연구에 활용될 수 있도록 지속적으로 업데이트될 예정이다.

참고문헌

[1] Yan, J., et al. (2026). "Dual Frequency Branch Framework with Reconstructed Sliding Windows Attention for AI-Generated Image Detection." IEEE Transactions on Information Forensics and Security (TIFS).

[2] Frank, J., et al. (2020). "Leveraging Frequency Analysis for Deep Fake Image Recognition." International Conference on Machine Learning (ICML 2020).

[3] DiffusionFake. (2024). "DiffusionFake: Enhancing Generalization in Deepfake Detection via Guided Stable Diffusion." Conference on Neural Information Processing Systems (NeurIPS 2024).

[4] FreqNet. (2024). "Frequency-Aware Deepfake Detection: Improving Generalizability through Frequency Space Learning." AAAI Conference on Artificial Intelligence (AAAI 2024).

[5] Wang, S.-Y., Wang, O., Zhang, R., Owens, A., & Efros, A. A. (2020). "CNN-generated images are surprisingly easy to spot... for now." IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2020). arXiv:1912.11035.

[6] Wong, K., Zhou, J., Wu, H., Si, Y.-W., & Zhou, J. (2025). "ADCD-Net: Robust Document Image Forgery Localization via Adaptive DCT Feature and Hierarchical Content Disentanglement." arXiv:2507.16397.

[7] 경찰청. (2024). 허위 영상물 범죄 발생 현황 통계. 서울: 경찰청.