주파수 분석을 이용한 AI 생성 이미지 탐지 연구

Research on AI-generated image detection using frequency analysis

팀명	Way-V
지도 교수	이정훈 교수
팀원	20231270 박지민 20201496 심준용 20211243 정예성

INDEX

Way-V project

01 연구 배경 및 동기

02 이론적 배경

03 선행 연구 & 모델 소개

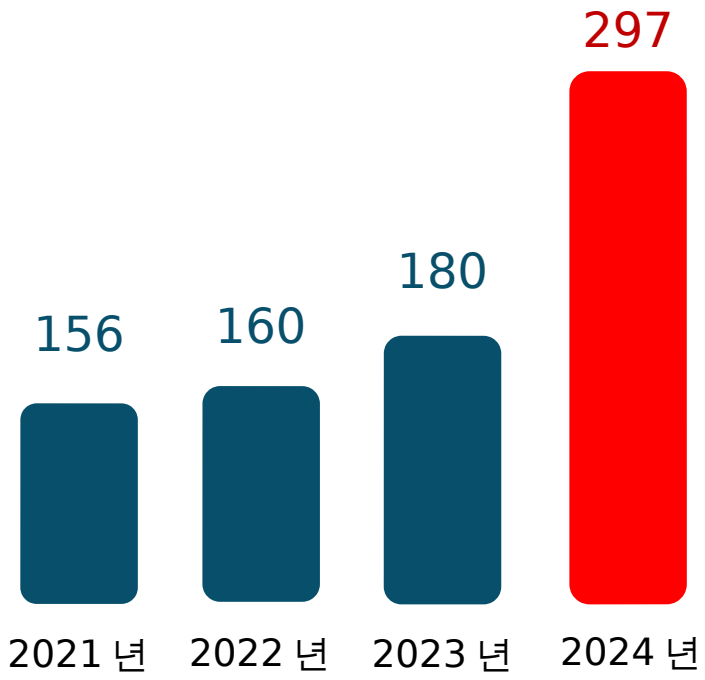
04 모델 실험 & 결과 분석

05 프로토타입

01 연구 배경 및 동기

연구 배경 및 필요성

허위 영상물 범죄 발생 현황



자료 =< 경찰청 >



'야구장 비매너' 맹승지, 1200만 야구팬 분노케 한 한 마디 "그냥 트렌드"...AI면 용서되는가? [SS이슈]

표권향 입력 2026. 5. 10. 16:34 수정 2026. 5. 10. 16:36

챗GPT 생성 '야구장 관중(중계 화면)' 논란
테이블 위로 두 다리 올려...유치원생도 아는 '선' 넘어
해설위원이 혀를 찬 문제의 영상 따라 해

맹승지가 최근 개인 SNS에 게재한 생성형 AI 제작 '야구장 관중(중계 화면)' 영상으로 비매너 논란에 올랐다. 사진 | 맹승지 SNS

무엇이 진짜입니까 ?

FAKE

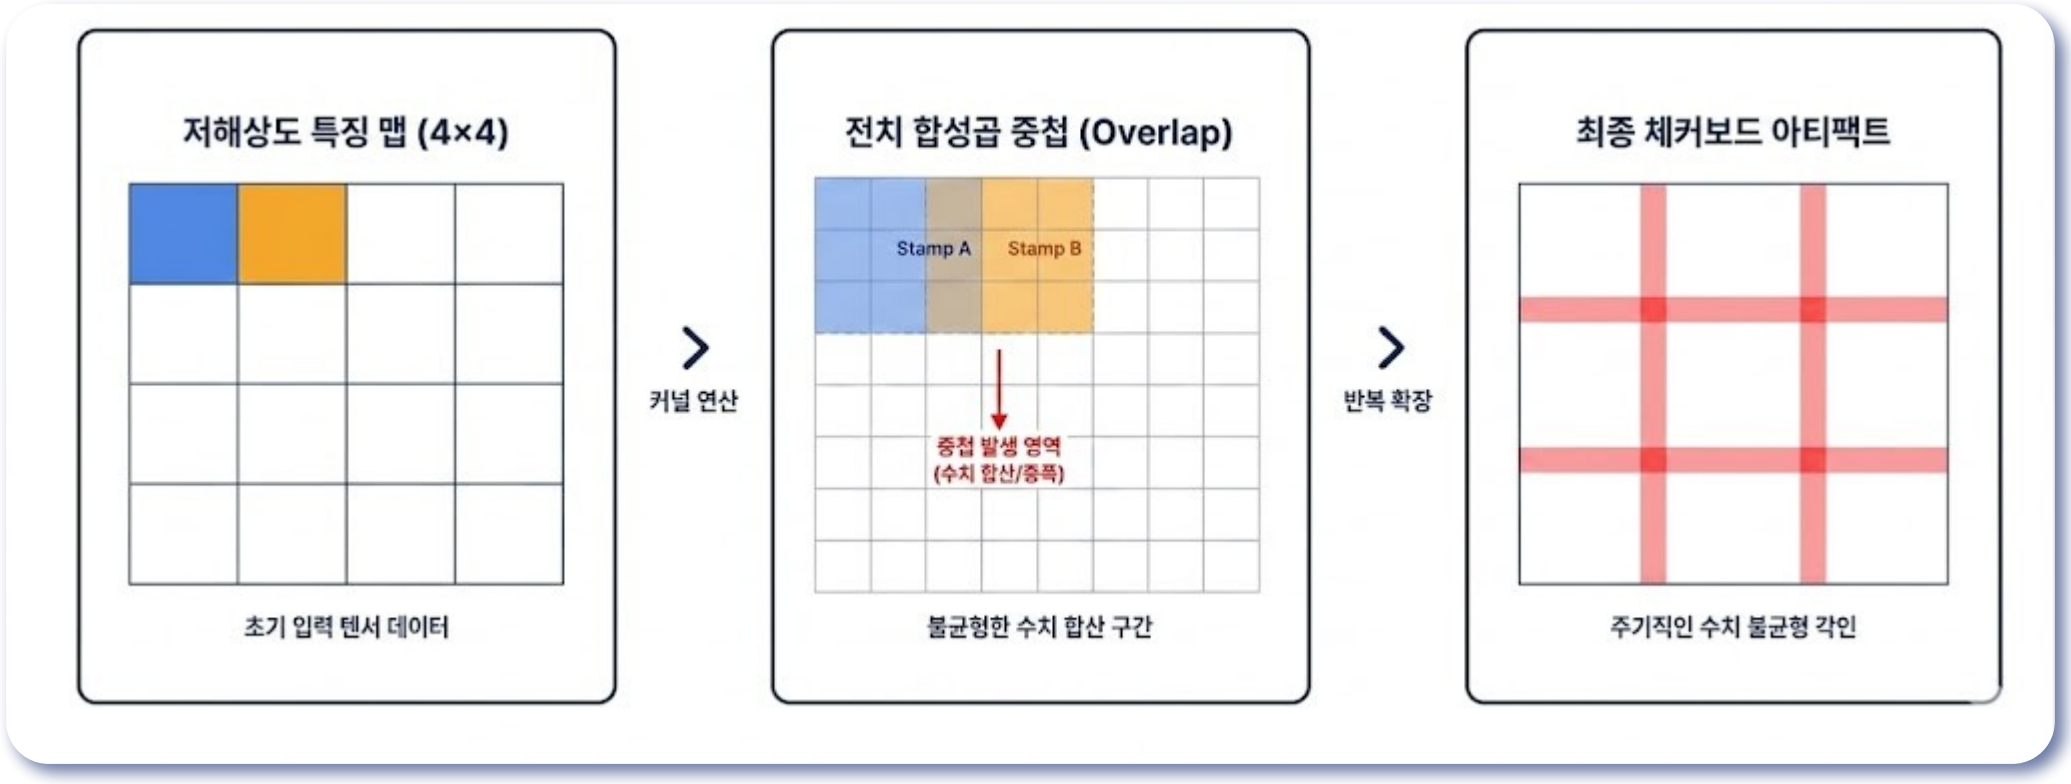


REAL



02 이론적 배경

업샘플링 과정



CNN 기반 탐지 : 아티팩트 패턴 암기 -> 범용성 떨어짐

고도화된 생성 모델의 아티팩트 은폐

01 Diffusion 모델

- 이미지를 강제로 키우는 방식 X
- 여러 단계의 반복적 노이즈 제거 연산으로 이미지를 생성
- GPT(DALLE-3), Gemini(Imagen3)

02 GAN 의 업그레이드

- 과거와 동일한 이미지 확대 공정
- 경계선에서의 픽셀이 깨지는 현상 억제

03 Transformer 기반

- 패치 (조각) 단위 관계 연산 : 이미지 전체 구조를 동시에 파악
- 공간적 불연속성 , 부분적 연산 오류 최소화 .

픽셀에서 주파수로

공간 도메인
(Pixel)

RGB 픽셀 배열 기반
시각적 인지 능력의 한계 도달
생성 모델의 조작 아티팩트 은닉

→

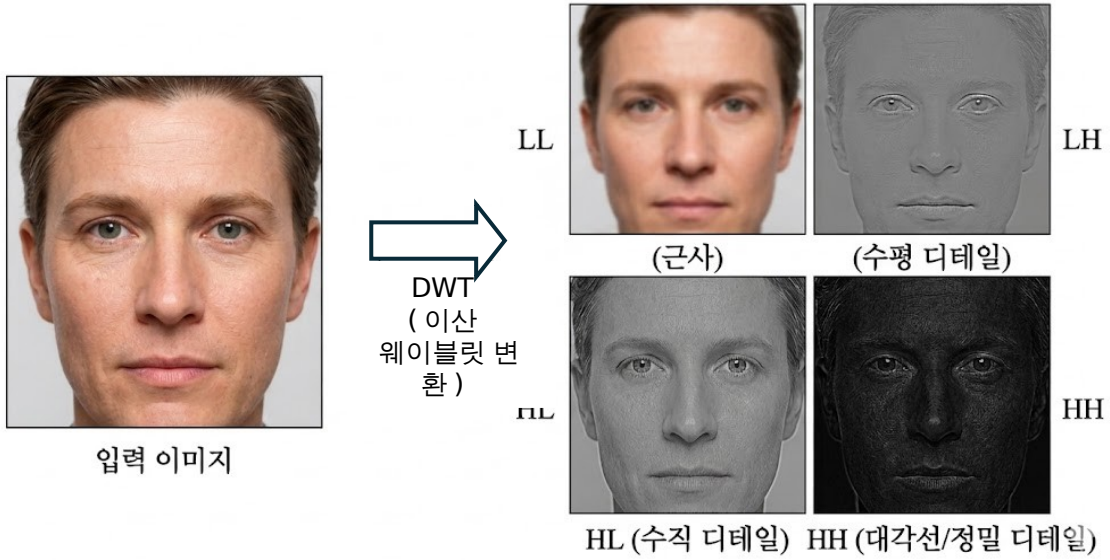
변환

Fourier / Wavelet
Transform 적용

주파수 도메인
(Frequency)

스펙트럼 분석 기반 위조 식별
통계적 불균형을 통한 정량적 탐지

핵심 기술 : DWT (이산 웨이블릿 변환)



LL 저주파 성분
전체 윤곽 · 형태 보존

LH 수직 고주파
수평 경계 · 에지 포착

HL 수평 고주파
수직 경계 · 포착

HH 대각선 고주파
미세 노이즈 · 연산 지문

다중 해상도 분석

이미지를 동시에 여러 해상도에서 분석하여 미세한 수준의 아티팩트 포착

HH 대역 집중 포착

HH(대각선 고주파) 대역에 집중적으로 남는 미세한 노이즈 탐지

위치 정보 보존

위조가 발생한 공간적 좌표를 유지하며 주파수를 추출

핵심 기술 : FFT (고속 푸리에 변환)

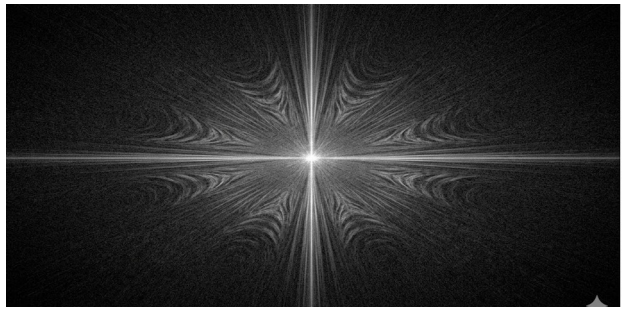


입력 이미지

⊓

FFT(고속 푸리에 변환)

▽



주파수 스펙트럼

전역적 주파수 분석

이미지 전체의 주파수 성분을 스펙트럼 형태로 한눈에 파악 .

규칙적 격자 노이즈 (Grid Artifacts) 추적

생성형 AI 가 학습 과정에서 남기는 고유의 아티팩트 탐지

비정상적 주파수 증폭 시각화

위조 흔적이 뚜렷한 점이나 선 (Peak) 의 형태로 선명하게 발현

03 선행 연구 & 모델 소개

선행 연구 분석 개요

업샘플링 기반 DCT 주파수 탐지

Leveraging Frequency Analysis for Deep Fake Image Recognition (ICML 2020)

- GAN 의 업샘플링 과정에서 구조적으로 발생하는 규칙적인 격자 패턴을 규명
- DCT(이산 코사인 변환) 를 이용해 주파수 도메인에서 이를 탐지

Diffusion 기반 딥페이크 탐지

DiffusionFake: Enhancing Generalization in Deepfake Detection via Guided Stable Diffusion (NeurIPS 2024)

- 사전 학습된 Stable Diffusion 모델을 가이드로 활용
- 딥페이크 생성 과정을 역추적

FFT 기반 주파수 공간 특징 학습

Frequency-Aware Deepfake Detection: Improving Generalizability through Frequency Space Learning ((AAAI 2024)

- FFT 기반 주파수 특징 공간 구축
- 주파수 도메인 내 위조 패턴 직접 학습 구조 제시

공통 데이터셋 구조

Train Dataset — Total 800 images

Real — **DeepDetect-2025 :** 고화질 실사 이미지 (400 장)

Fake — **Multi-Models:** StyleGAN3, Diffusion, Face-swap (400 장)

Test Dataset — Total 400 images

Real — **FaceForensics++:** 고화질 실사 이미지 (200 장)

Fake — **Multi-Models :** FF++, StyleGAN3, Diffusion (200 장)

선행 연구 테스트

테스트 결과

업샘플링 기반 DCT 주파수 탐지

ACC **51%**

AUC 0.519

단일 고주파 패턴 암기에 의존,
흔적이 복잡하게 분산된 최신 모델
탐지에 취약

흩어진 위조 신호를 다각도로
포착할 수 있는 다중 주파수 분석
접근법이
필요

Diffusion 기반 딥페이크 탐지

ACC **55%**

AUC 0.574

국소 정보 (DWT) 단일 분석만으로는
원본과 위조가 섞인 딥페이크의 전체
맥락 파악 부족

특정 위조 방식에만 국한되지
않도록, 이미지의 세부 변형과
구조적 특징을 모두 학습,
탐지할 수 있는 다각적인 주파수
분석 시야 확장 필요

FFT 기반 주파수 공간 특징 학습

ACC **55.2%**

AP 57.4%

주파수 단순 입력 시, 모델 스스로 주변
픽셀들의 관계를 능동적으로 비교·
분석하는 능력 취약

모델 내부에서 인접 영역들
사이의
위조 차이를 스스로 세밀하게
뜯어보고 분석할 수 있는 내부
구조 개선 필요

DFFReq 모델 선정 근거

1 차 검증 · 동일 조건 (Train 800 장 / Test 400 장)

선행연구 3 편과 동일한 데이터셋으로 비교 → DFFreq 의 우위를 직접 수치로 확인

모델	ACC	AUC / AP
Frank et al. (ICML 2020)	51%	AUC 0.519
DiffusionFake (NeurIPS 2024)	55%	AUC 0.574
FreqNet (AAAI 2024)	52.2%	AP 57.4%
DFFreq (TIFS 2026)	**60.75%**	**AUC 0.675**

→ 동일 조건에서 기존 3 편 대비 +5~10%p 향상

2 차 검증 · 데이터 확장 (Train 11,000 장 / Test 3,000 장)

ACC	AP
76.2%	68.1%

데이터 증가 → ACC 76.2% 로 개선 확인 주파수 아티팩트 탐지 일반화 가능성 입증

DFFreq 선정 — 기술적 근거

01 이중 주파수 분기 (DWT + FFT)
DWT (국소 공간 주파수 특징) + FFT 위상 (이미지 전체 구조 패턴)
→ 두 관점에서 위조 흔적 동시에 포착 , 기존 단일 주파수 한계 극복

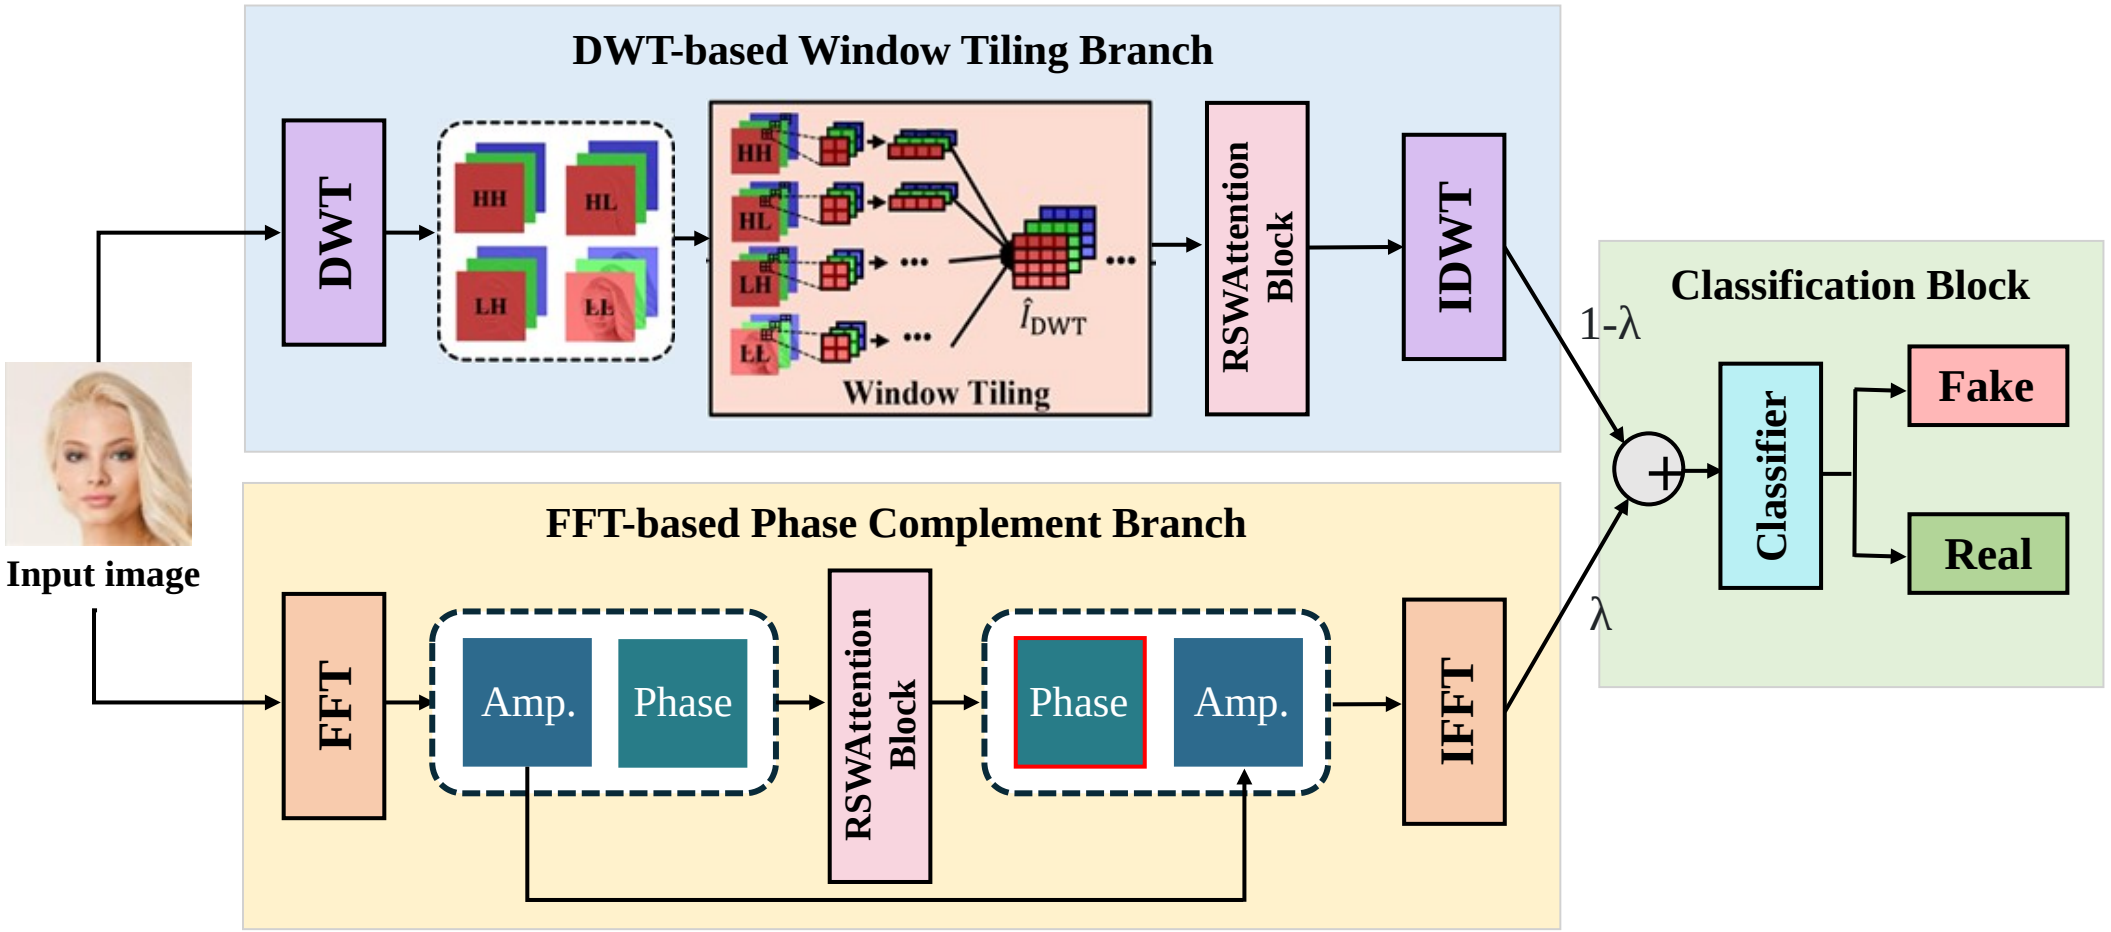
02 논문 공식 성능 — SOTA 수준
ACC 92.1% · AP 94.7% (65 개 모델 대상)
→ 기존 SOTA 대비 +2.13%p, GAN·Diffusion 모두 대응

03 ProGAN 학습 → 다양한 모델 탐지
단일 GAN 으로 학습해도 Diffusion 모델까지 탐지 가능
→ 도메인 갭 문제 해결 가능성 · 얼굴 특화 학습 설계 근거

수치 검증 + 구조적 우위 → DFFreq 최종 선정

모델 소개 (DFFReq)

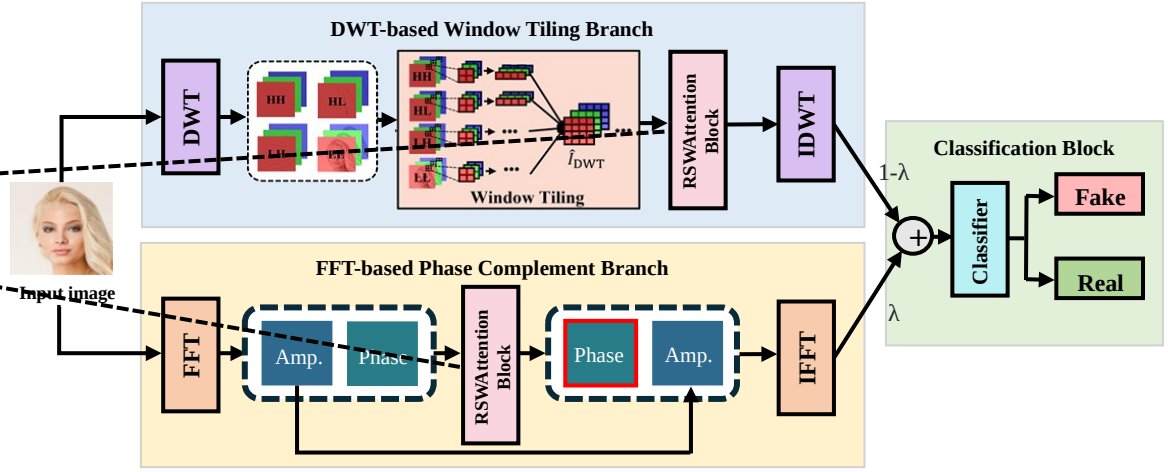
서로 다른 두 가지 관점 (DWT, FFT) 으로 이미지를 검사하는 이중 분기 프레임워크 (Dual Frequency Branch)

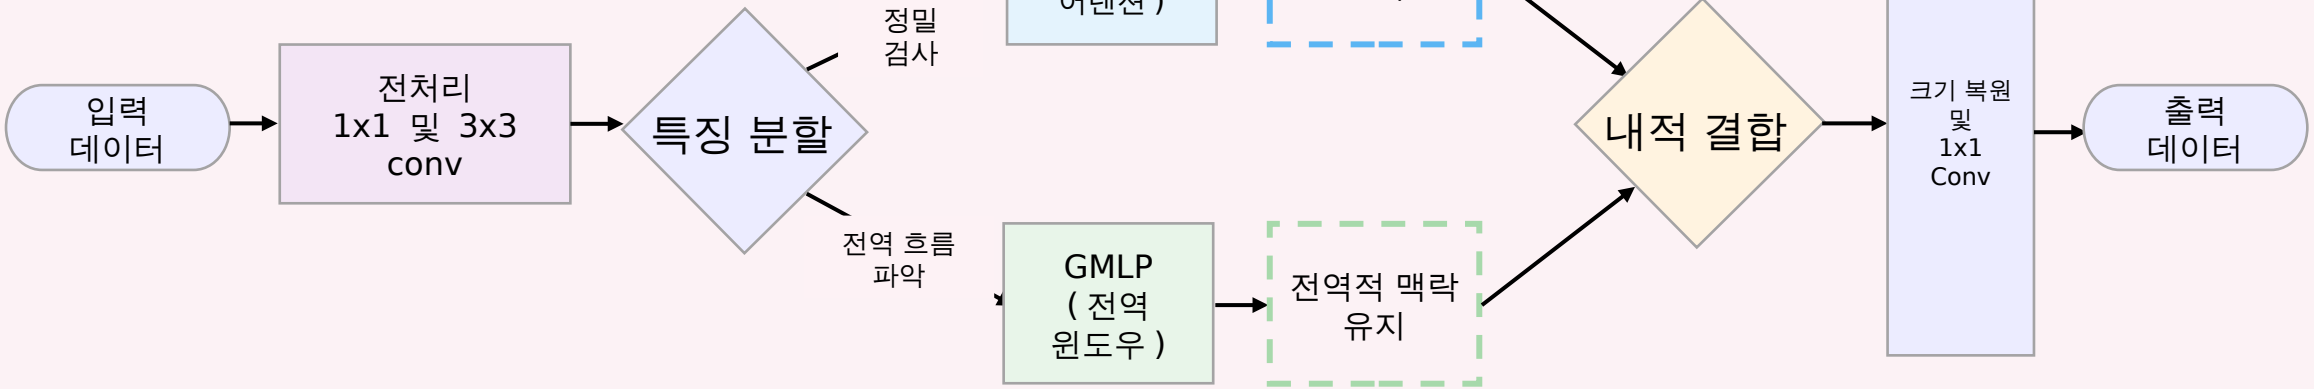


DFFReq – RSWAttention

RSWAttention Block

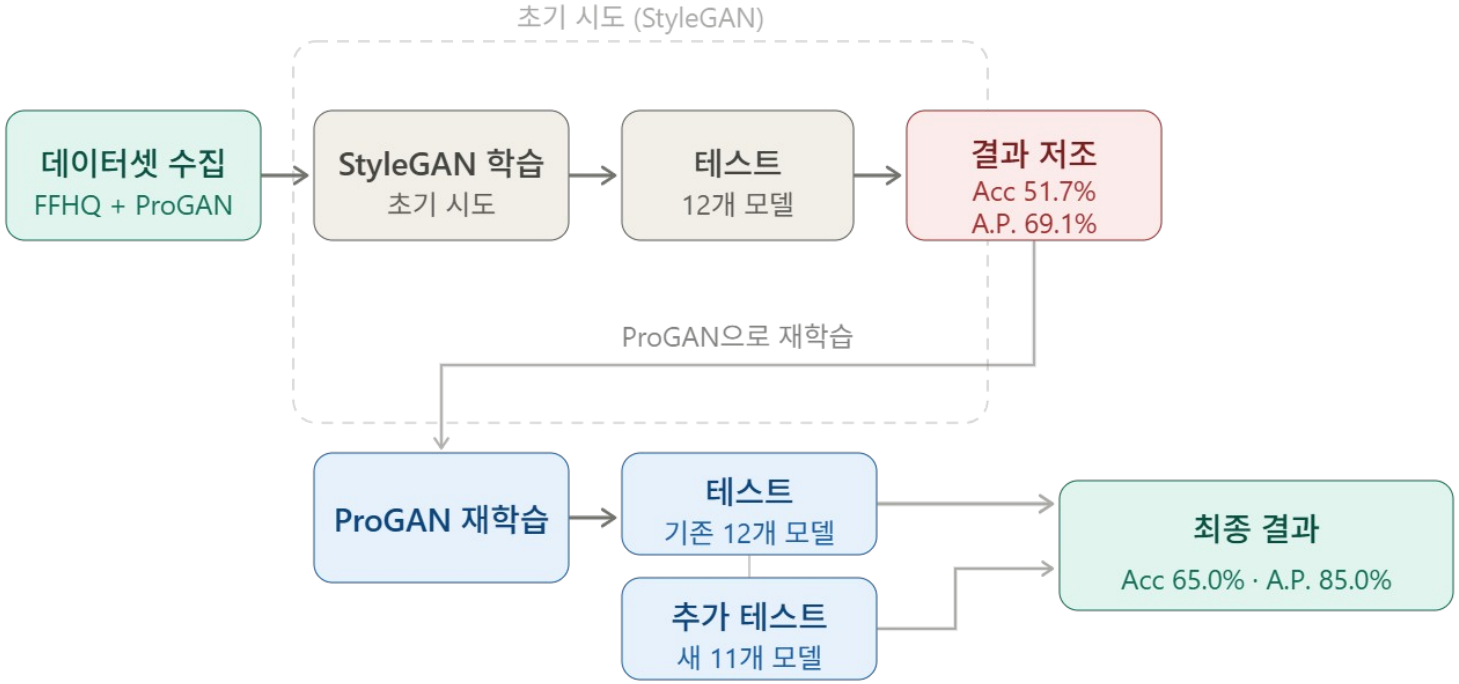
수집된 특징에서 위조 신호를
발견하고
검증하는 정밀 분석 블록





04 모델 실험 & 결과 분석

연구 개요



학습 도메인

얼굴 특화 (Face Only)

얼굴 이미지에 집중해 탐지 경계를 더 뚜렷하게 학습

학습 환경

RTX 3090 / Batch 32 / 90 Epochs / lr 2e-4

안정적 학습을 위해 배치 크기 조정

PNG 형식 고주파 성분을 버리지 않아 DWT·FFT 가 잡는 위조 흔적이 그대로 보존

데이터셋 구성

학습 데이터 Train

Real

40,000 장

FFHQ 얼굴

Fake

40,000 장

ProGAN 생성

- Train : Val = 9 : 1
- Val 4,000 장 (Real 2,000 + Fake 2,000)

테스트 데이터 Test

총 23 개 모델

GAN 12 종

AttGAN · BEGAN · CramerGAN · InfoMaxGAN · MMDGAN · RelGAN
SNGAN · STGAN · StyleGAN-XL · StyleGAN3 · StyleSwim · R3GAN

Diffusion 4 종

FLUX1_dev · FLUX1_schnell · SDXL · BLIP

Face Swap 5 종

BlendFace · E4S · FaceSwap · InSwap · SimSwap

Personalized 2 종

InstantID · PhotoMaker

ProGAN 재학습

StyleGAN2/3 학습

Mean Acc	A.P.
51.7%	69.1%

→

ProGAN 학습

Mean Acc	A.P.
65.0%	85.0%

StyleGAN2/3 학습의 한계 Style Mixing(각 레이어에서 스타일을 세밀하게 조절) 과 AdaIN(정규화) 가 artifact 를 도메인 특화 패턴으로 만들어 다른 모델에 일반화되지 않음

ProGAN 학습의 특징 4×4 → 8×8 → ... → 1024×1024 순서로 레이어를 점진적으로 추가 (Progressive Growing)

각 해상도 전환마다 업샘플링이 발생 , 이 과정에서 DWT 의 HH·HL·LH 서브밴드에 grid artifact 가 생성
이 패턴은 다른 GAN 과 Diffusion 모델에도 유사하게 존재해 일반화 가능

전체 실험 결과 요약

GAN

12 종 | Mean A.P. 86.0%

	Acc	A.P.
AttGAN	58.5	70.9
BEGAN	82.8	83.0
CramerGAN	63.1	94.0
InfoMaxGAN	53.0	88.6
MMDGAN	78.7	98.8
RelGAN	93.9	97.9
StyleSwim	94.3	98.5
SNGAN	50.5	67.0
STGAN	65.9	99.6
R3GAN	94.5	94.8
StyleGAN-XL	82.0	85.5
S3GAN (*Non-face)	50.4	53.8

Diffusion

4 종 | Mean A.P. 91.5%

	Acc	A.P.
FLUX1_dev	61.2	91.4
FLUX1_schnell	71.0	96.5
SDXL	51.1	78.8
BLIP	98.8	99.4

Face Swap

5 종 | Mean A.P. 53.9%

	Acc	A.P.
BlendFace	43.9	43.0
E4S	44.9	45.1
FaceSwap	50.4	64.5
InSwap	51.8	61.4
SimSwap	47.9	55.3

Personalized

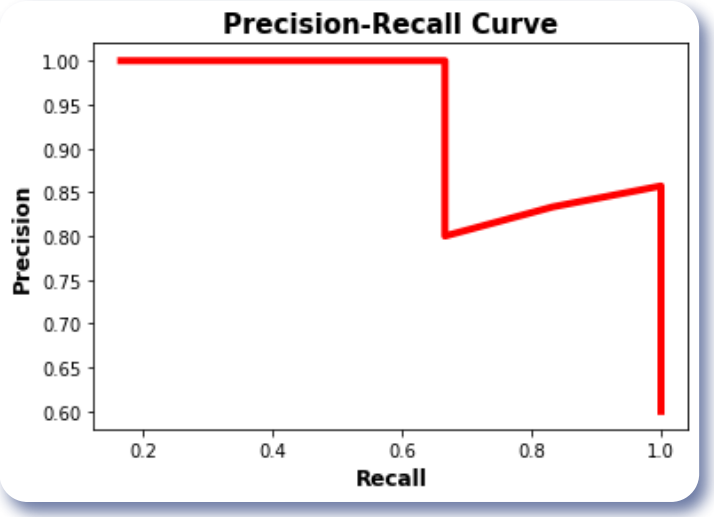
2 종 | Mean A.P. 96.2%

	Acc	A.P.
InstantID	94.1	97.6
PhotoMaker	92.1	94.7

***A.P.** : Average Precision, 평균 정밀도

유동적인 임계값(Threshold)에 따른 정밀도와 재현율의 상관관계

$$A.P. = \int_0^1 p(r)\,dr$$



결과 분석

얼굴 특화 탐지

모델	논문 A.P.	Ours A.P.
AttGAN	99.8	70.9
BEGAN	99.7	83.0
CramerGAN	99.7	94.0
InfoMaxGAN	99.7	88.6
MMDGAN	99.8	98.8
RelGAN	99.9	97.9
StyleSwim	98.6	98.5
SNGAN	99.6	67.0
STGAN	100.0	99.6
R3GAN	94.9	94.8
StyleGAN-XL	86.4	85.5

모델	논문 A.P.	Ours A.P.
FLUX1_dev	96.8	91.4
FLUX1_schnell	-	96.5
SDXL	98.7	78.8
BLIP	99.7	99.4
InstantID	97.7	97.6
PhotoMaker	95.2	94.7

결과 분석

S3GAN (Non-face)

논문 Acc: 88.2 ; A.P: 91.1 Ours Acc: 50.4 ; A.P: 53.8

S3GAN 은 semantic segmentation map 을 입력받아 자동차 · 건물 등 사물 이미지 생성 모델

얼굴만 학습 → 사물 도메인의 artifact 패턴을 전혀 학습하지 못함 → 탐지 불가





Face Swap

	논문		Ours	
모델	Acc	A.P.	Acc	A.P.
BlendFace	44.1	44.0	43.9	43.0
E4S	45.1	46.4	44.9	45.1
FaceSwap	50.8	66.8	50.4	64.5
InSwap	52.1	63.7	51.8	61.4
SimSwap	48.4	57.7	47.9	55.3

Face Swap 은 얼굴 영역만 합성하고 배경은 원본 유지

→ 경계 artifact 가 얼굴 바깥에 발생 얼굴만 학습하여 비얼굴 영역 패턴 탐지 저조

한계 및 향후 과제

학습 도메인 부족

우리 학습 데이터 FFHQ 얼굴 40,000 장 (real) + ProGAN 생성 얼굴 40,000 장 (fake) — 단일 도메인

한계 얼굴 외 도메인 (사물 , 배경 , 합성 경계) 의 artifact 패턴을 전혀 학습하지 않음 → S3GAN 저조 직접 원인

FaceSwap 이미지의 얼굴 경계 artifact 를 탐지하지 못함

논문 설정 car·cat·chair·horse 4 개 도메인으로 학습 → 각 도메인에서 업샘플링 artifact 의 공통 패턴 추출 → 보편적 탐지 성능 확보

향후 연구 방향

01 멀티 도메인 학습

얼굴 + 사물 (LSUN) 혼합 학습
→ 학습 도메인과 다른 도메인 테스트 결과 저조 문제 해결
얼굴 특화 장점은 유지하면서 범용성 확보 기대

02 A.P. 임계값 재보정

모델 학습 검증 단계에서의 최적 임계값 (Threshold) 를 찾아 재설정

→ 모델에 잠재된 높은 변별력을 온전히 끌어내어 실전 탐지 정확도를 획기적으로 향상 기대

03 FaceSwap 특화 분류기 λ(람다)값 재설정

국소 미세 질감을 탐지하는 DWT 브랜치의 비중을 극대화하여 λ값 축소
→ FaceSwap 경계 artifact 특화 탐지 기대(전체 정확도 감소)
탐지 가능하다면 선택 분류기로 업그레이드

05 프로토타입

프로토타입 소개

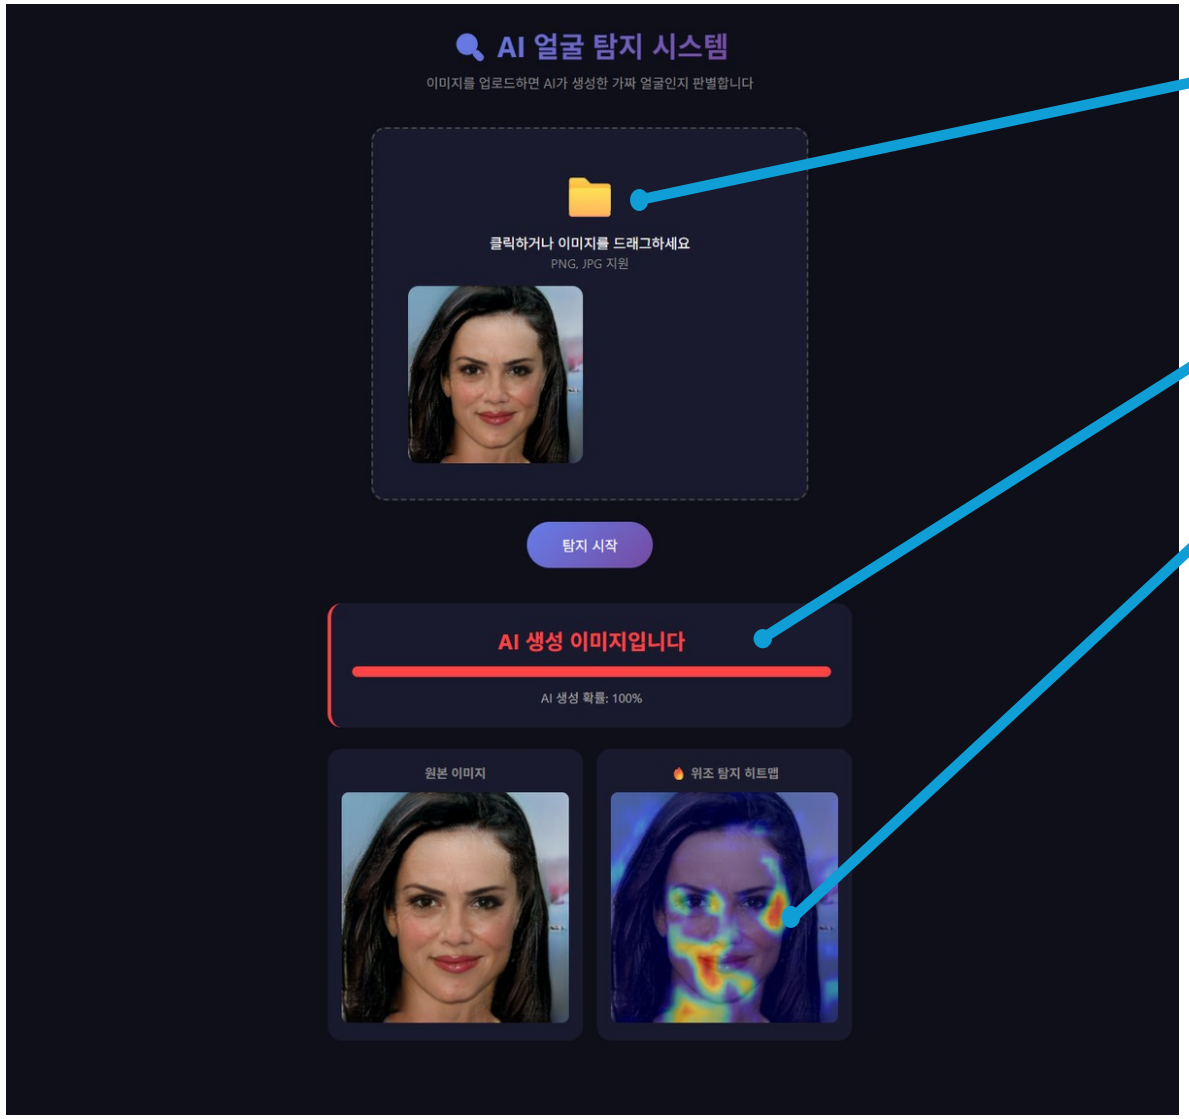


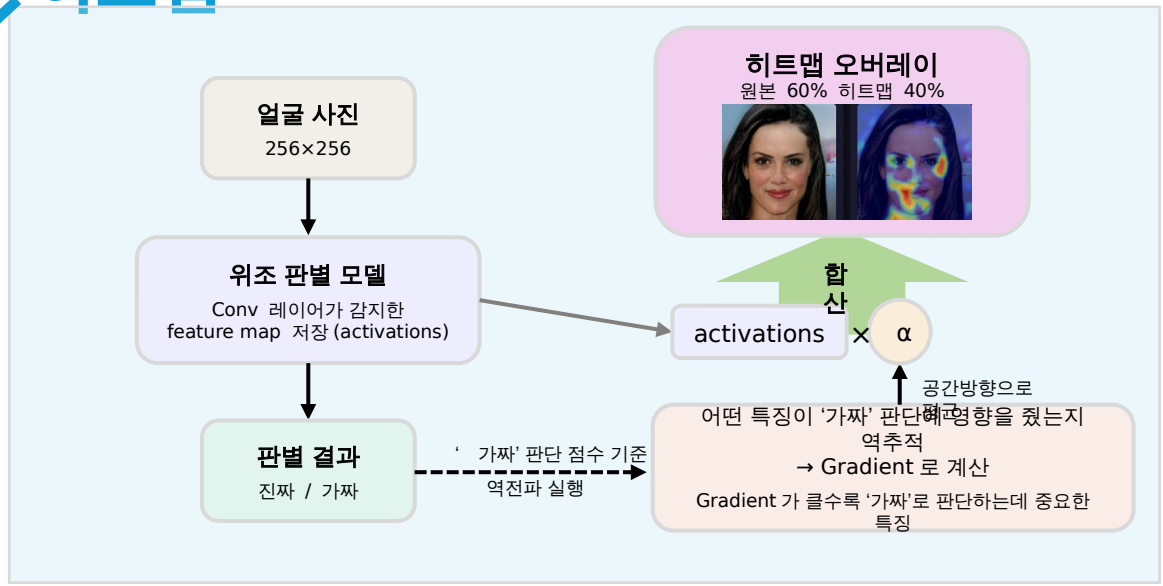
사진 업로드

png, jpg 파일 지원

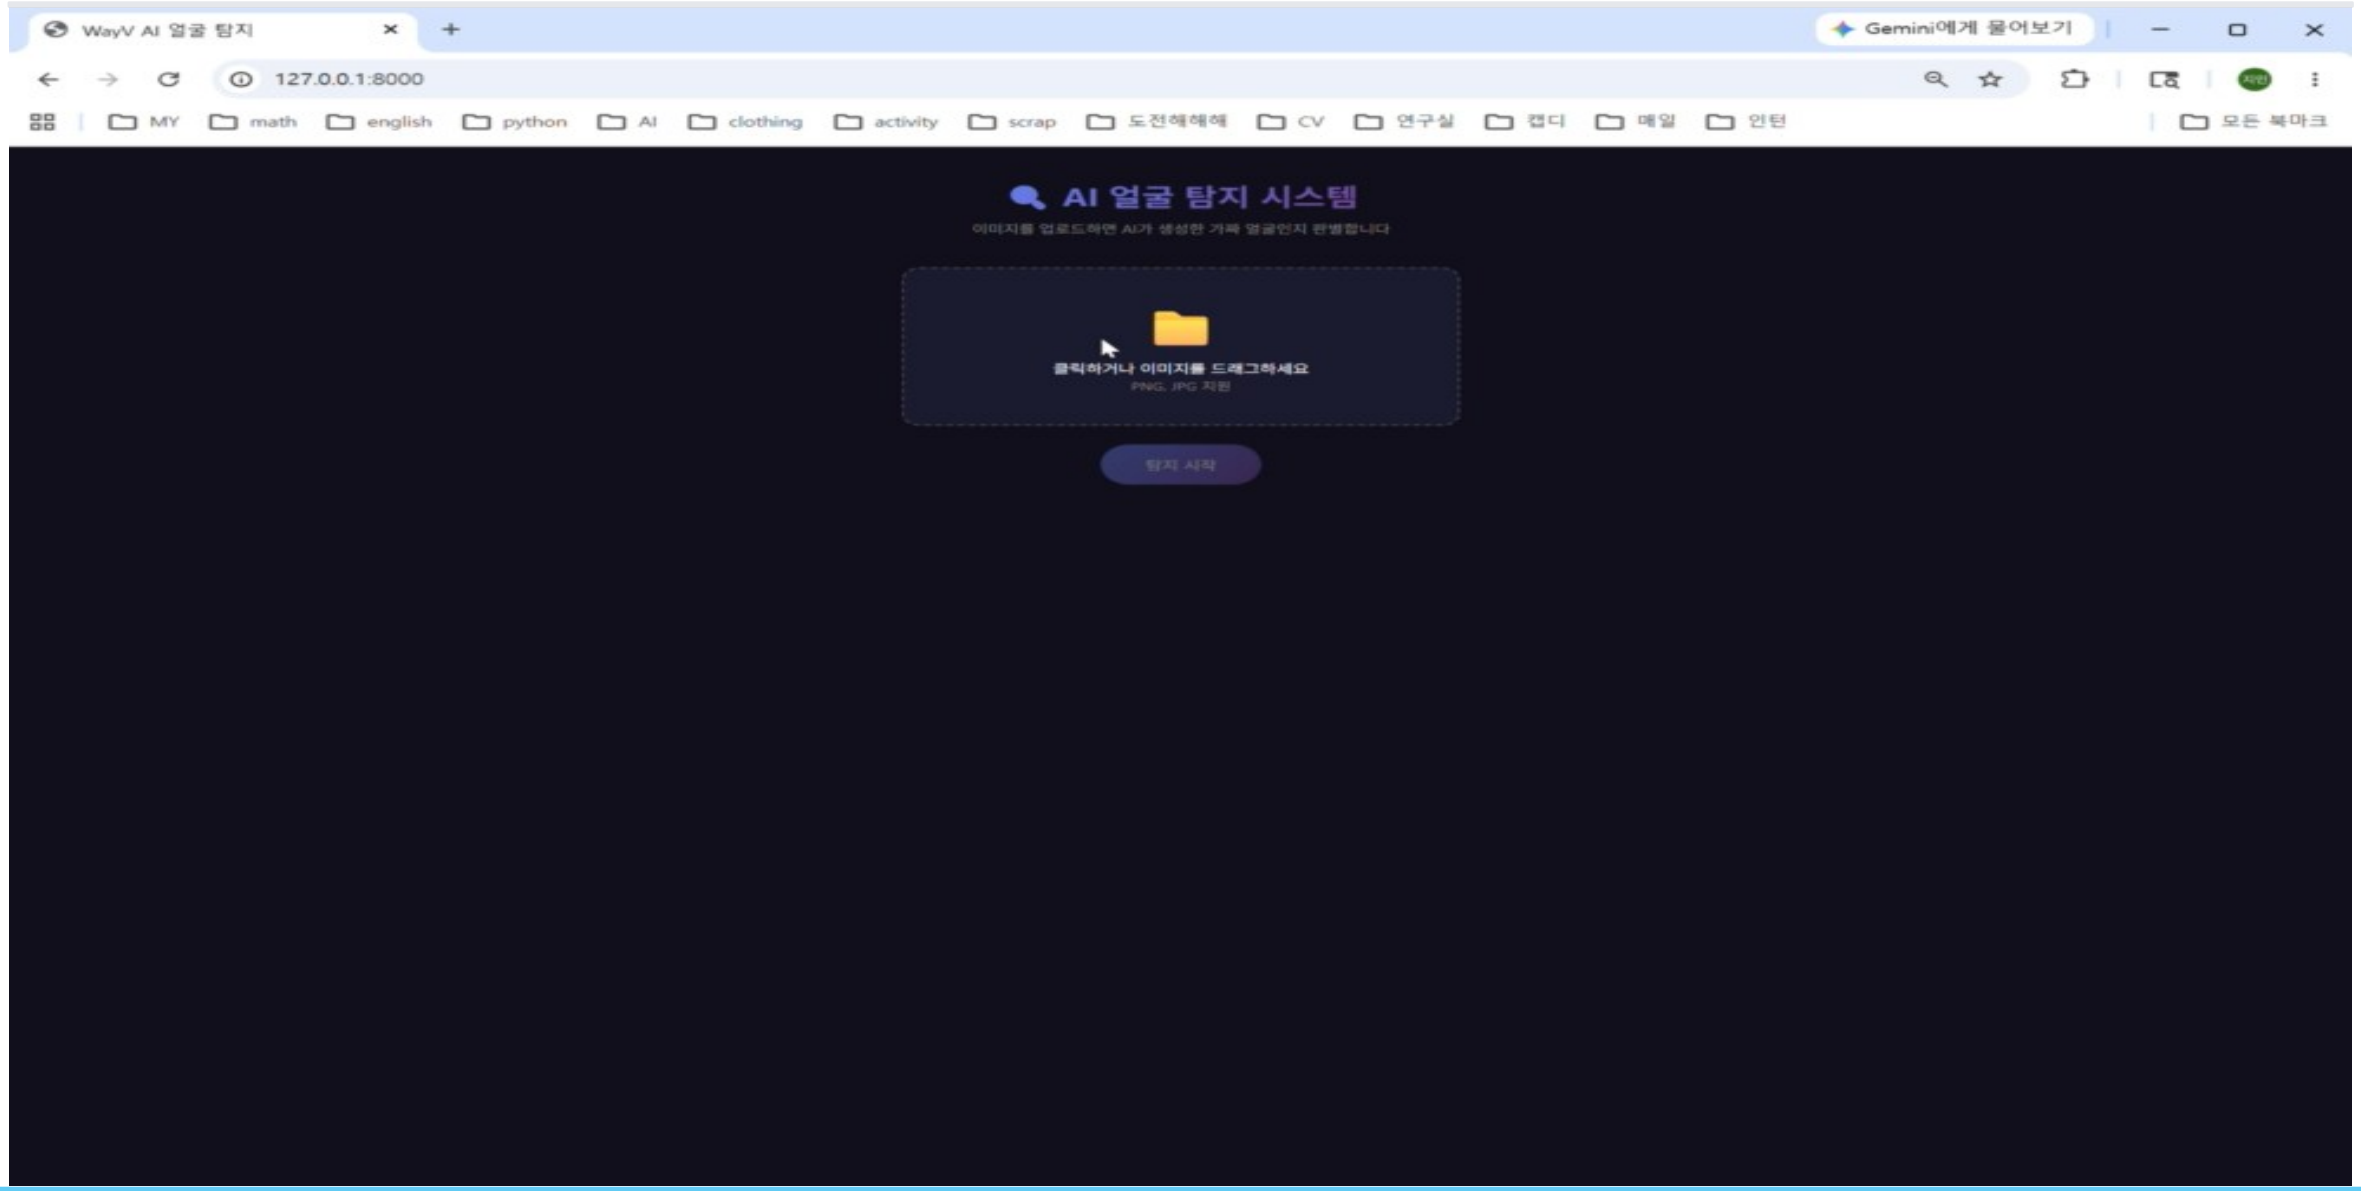
판정

90% 이상 → AI 생성 이미지입니다
70~90% → AI 생성 이미지로 의심됩니다
30~70% → 판단이 어렵습니다
30% 이하 → 실제 이미지입니다

히트맵 모델이 판단한 근거 영역을 시각화



프로토타입 시연


WayV AI 얼굴 탐지
Gemini에게 물어보기
127.0.0.1:8000
MY
math
english
python
AI
clothing
activity
scrap
도전해해해
CV
연구실
캡디
메일
인턴
모든 북마크
AI 얼굴 탐지 시스템
이미지를 업로드하면 AI가 생성한 가짜 얼굴인지 판별합니다
클릭하거나 이미지를 드래그하세요
PNG, JPG 지원
탐지 시작

결론 및 기대효과

결론

1 기존 딥페이크 탐지 모델의 한계 확인

- 선행연구 3 편 재현 결과 , 평균 ACC 50~55% 수준에 머묾
- 특정 생성 방식의 흔적만 ' 암기 ' 하여 판단하는 구조적 한계 (Domain Gap) 규명

2 이중 주파수 기반 프레임워크 (DFFreq) 도입

- 공간 도메인에서 보이지 않는 위조 흔적을 주파수 영역 (DWT+FFT) 에서 다각도로 탐지
- 얼굴 특화 학습만으로 ProGAN, SDXL, FLUX 등 주요 생성 모델에 논문 수준의 탐지 성능 달성

3 학습 데이터 도메인이 일반화 성능의 핵심임을 실험으로 검증

- StyleGAN2/3 → ProGAN 재학습만으로 성능 향상
  (Mean Acc : 51.7% → 65.0%, A.P. : 69.1% → 85.0%)
- 얼굴 특화 학습의 강점과 도메인 불일치 한계를 동시에 규명 ,
  멀티 도메인 학습의 필요성 도출

기대효과

1 생성 방식에 구애받지 않는 ' 범용 탐지력 ' 확보

- DWT(국소 공간 주파수) + FFT 위상 (이미지 전체 구조 패턴) 으로 위조 흔적 다각도 포착
- GAN · Diffusion 등 다양한 AI 모델에 대응 가능

2 대중적인 프로토타입 시스템 구현

- 사진 한 장 업로드만으로 AI 생성 여부 즉시 판별
- 히트맵으로 ' 판단 근거 ' 를 일반 사용자도 직관적으로 확인 가능

3 실질적인 사회적 피해 예방 및 신뢰 회복

- 명예훼손 , 허위 제보 , 위조 신분증 등 딥페이크 악용 디지털 범죄 사전 차단
- 디지털 사진 및 영상 증거에 대한 사회적 신뢰를 회복하는 인프라로 확장

Q & A

참고문헌

- Leveraging Frequency Analysis for Deep Fake Image Recognition (ICML 2020)

- DiffusionFake: Enhancing Generalization in Deepfake Detection via Guided Stable Diffusion (NeurIPS 2024)

- Frequency-Aware Deepfake Detection: Improving Generalizability through Frequency Space Learning (AAAI 2024)

- Yan, Jiazhen, et al. "Dual frequency branch framework with reconstructed sliding windows attention for ai-generated image detection." *IEEE Transactions on Information Forensics and Security* (2026).

테스트셋 데이터 특징

GAN 계열 (12 종)

- **Progressive Growing (R3GAN·StyleSwim)**

  업샘플링 반복 → DWT HH 서브밴드에 규칙적인 artifact 생성

- **StyleGAN 계열 (StyleGAN-XL)**

  W space 스타일 변환 ·AdaIN → artifact 복잡

- **안정화 계열 (SNGAN)**

  Spectral Norm 등 고주파 억제 → artifact 감소

Diffusion 계열 (4 종)

- **노이즈 디노이징 구조**

  픽셀간의 연속성이 높음

- **구조적 & 논리적 오류**

  공간의 물리적 법칙 및 3D 공간의 이해 부족

Face Swap (5 종)

- **이미지 블랜딩 기법**

  얼굴 교체 후 색감과 조명 맞춤

- **합성 경계면의 부자연스러움**

  두 이미지의 경계면에서 비정상적인 고주파 노이즈 발생

Personalized (2 종)

- **참조 사진 기반 인물 생성**

  특정 인물 , 객체 , 혹은 화풍을 AI 에게 집중적으로 학습

- **InstantID**

  한 장의 사진에서 얼굴의 특징 (ID) 추출 → 얼굴의 뼈대 위치 고정

- **PhotoMaker**

  여러 장의 사진을 겹쳐 하나의 ID 임베딩 생성
  → 단어 (Token) 처럼 변환하여 텍스트 인코더에 밀어 넣는 방식

GAN·Face Swap

GAN 14 종

모델	Acc (%)	A.P. (%)	r_Acc (%)	f_Acc (%)
AttGAN	58.5	70.9	92.9	23.6
BEGAN	82.8	83.0	77.5	88.3
CramerGAN	63.1	94.0	99.8	25.9
InfoMaxGAN	53.0	88.6	99.8	5.6
MMDGAN	78.7	98.8	99.8	57.3
RelGAN	93.9	97.9	91.9	95.8
S3GAN	50.4	53.8	99.9	0.1
SNGAN	50.5	67.0	99.8	0.5
STGAN	65.9	99.6	100.0	31.2
ProGAN	99.8	100.0	100.0	99.5
R3GAN	94.5	94.8	90.3	98.6
StyleGAN-XL	82.0	85.5	89.6	74.5
StyleGAN3	93.3	98.1	91.0	95.7
StyleSwim	94.3	98.5	88.9	99.8
평균	**75.8**	**87.9**	**94.4**	**56.9**

Face Swap 5 종

모델	Acc	A.P.	r_Acc	f_Acc
BlendFace	43.9	43.0	83.6	3.8
E4S	44.9	45.1	84.5	5.0
FaceSwap	50.4	64.5	92.5	6.7
InSwap	51.8	61.4	93.0	8.9
SimSwap	47.9	55.3	92.4	3.4
평균	**47.8**	**53.9**	**89.2**	**5.6**

Diffusion · Personalized · Social

Diffusion 11 종

모델	Acc (%)	A.P. (%)	r_Acc (%)	f_Acc (%)
FLUX1_dev	61.2	91.4	100.0	21.7
FLUX1_schnell	71.0	96.5	100.0	41.5
SDXL (v1)	51.1	78.8	100.0	1.4
BLIP	98.8	99.4	97.8	99.9
DALLE-3	46.1	47.3	89.8	1.6
FLUX1-dev	92.9	96.6	89.0	96.7
GLIDE	94.0	98.4	92.5	95.5
Imagen3	93.4	95.9	89.7	97.1
Midjourney	87.0	93.1	76.9	97.0
SD3	95.3	97.4	91.9	98.8
SDXL	95.1	98.3	90.6	99.6
평균	**80.5**	**90.3**	**92.6**	**68.3**

Personalized 2 종

모델	Acc	A.P.	r_Acc	f_Acc
InstantID	94.1	97.6	89.6	98.5
PhotoMaker	92.1	94.7	88.9	95.2

소셜미디어 2 종

모델	Acc	A.P.	r_Acc	f_Acc
CommunityAI	54.8	61.7	99.6	9.4
SocialRF	59.8	71.4	99.1	20.5